



Universidade Estadual de Campinas
Faculdade de Engenharia Elétrica e de Computação



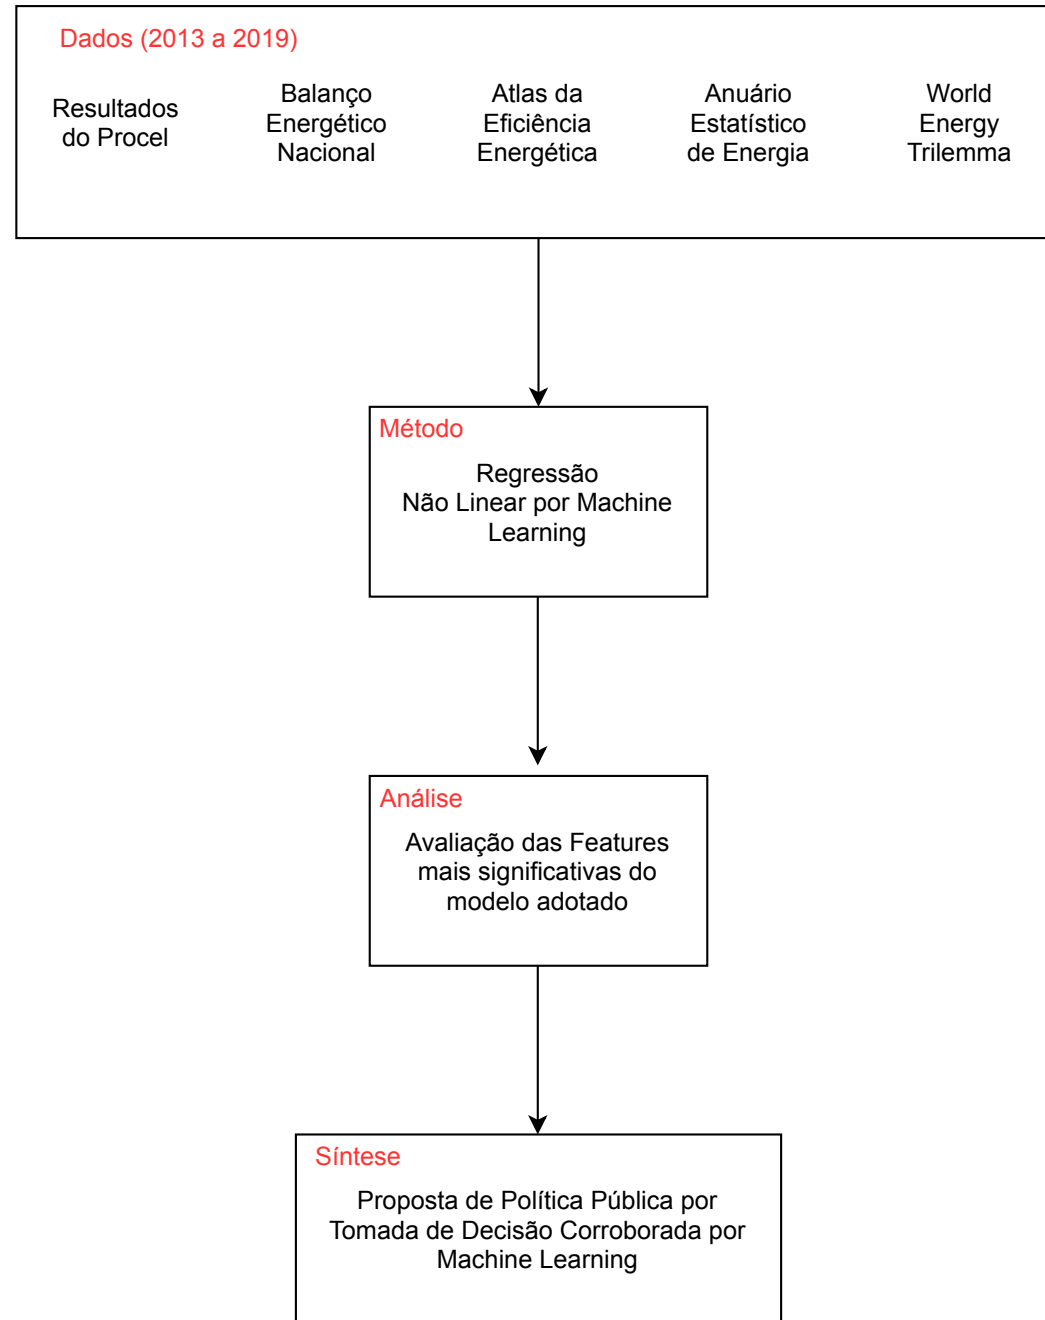
IT305G - Gestão de Energia e Eficiência Energética
Prof. Dr. Luiz Carlos Pereira da Silva e Prof. Msc João Ito

Regressão de Dados dos Anuários de Energia e Eficiência Energética para Tomada de Decisão em Políticas Públicas Utilizando Machine Learning

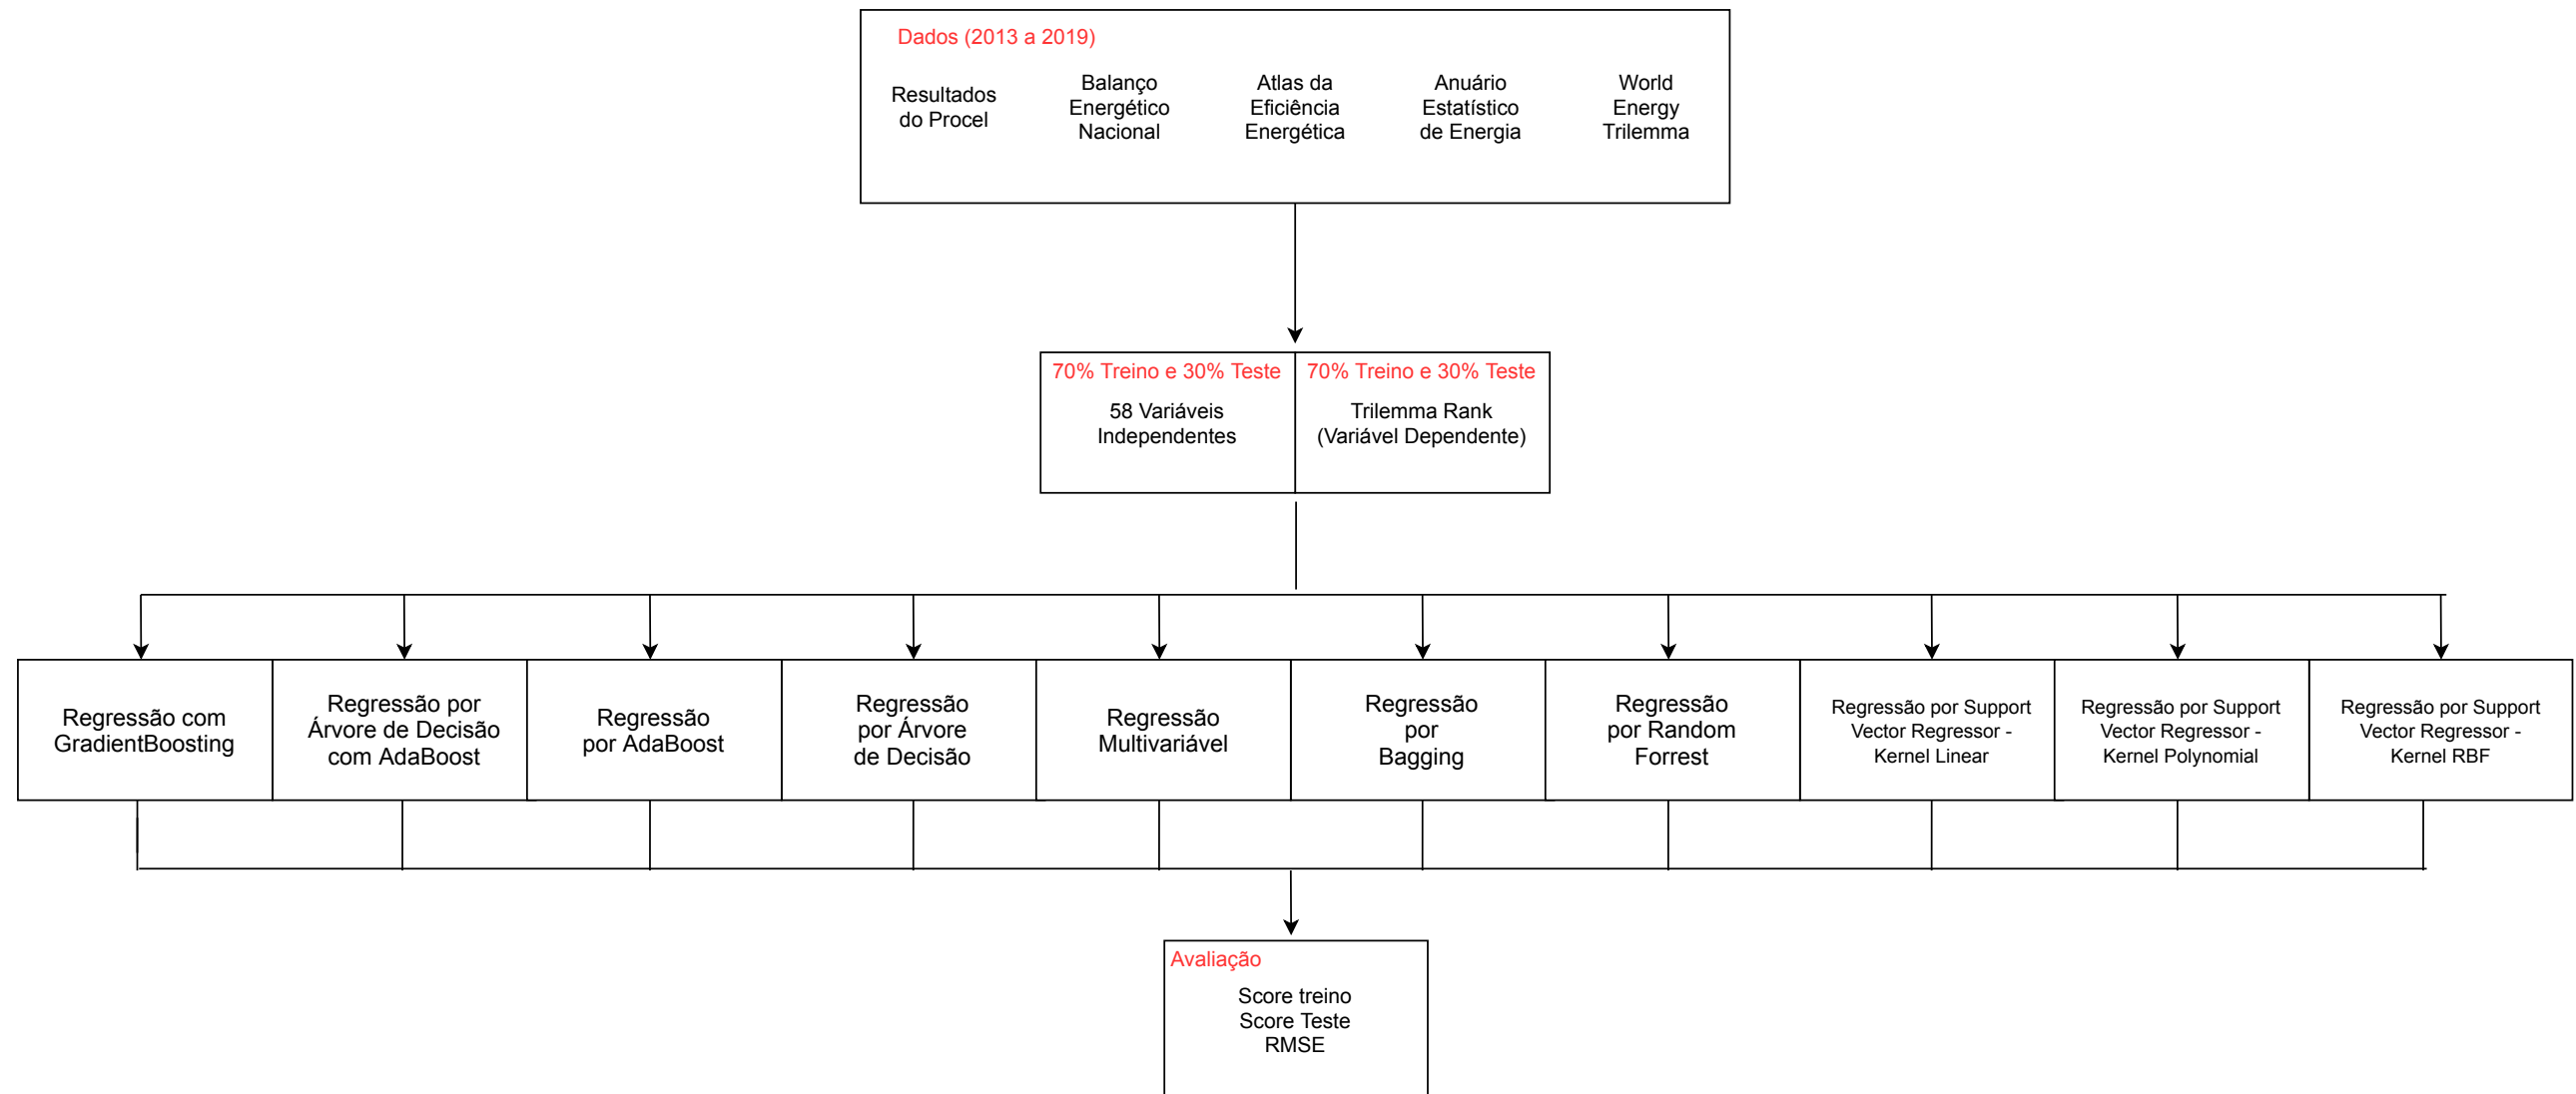
Aluno: Gleyson Roberto do Nascimento. RA: 043801.

Janeiro/2021

O Problema





O Método







Resultados I

Tabela 01 - Resultados das Regressões não Lineares feitas por Machine Learning





Posição	Método	Score de Treino	Score de teste	RMSE - Raíz do Erro Quadrático Médio
1	Regressão com GradientBoosting	0.9999999060685	0.930055664679408	0.154478588479773
2	Regressão por Árvore de Decisão com AdaBoost	0.889162561576354	0.948979591836734	0.131936203536836
3	Regressão por AdaBoost	0.889162561576354	0.948979591836734	0.131936203536836
4	Regressão por Support Vector Regressor - Kernel Polynomial	0.99018307556021	0.733055286436736	0.301788496308552
5	Regressão Multivariável	1	0.657599492165343	0.341789895132097
6	Regressão por Bagging	0.809579182630907	0.466085600907028	0.426803365676911
7	Regressão por Support Vector Regressor - Kernel Linear	0.990168652051838	0.612689391992557	0.363514479861328
8	Regressão por Random Forrest	0.783752287732621	0.400043845663265	0.452430396339587
9	Regressão por Support Vector Regressor - Kernel RBF	0.990157176414034	0.144717519805832	0.540190331461215
10	Regressão por Árvore de Decisão	0.997263273125342	-0.0306122448979591	0.592979483991658



Resultados II



Resultados III




Avaliação


Tabela 02 - Features mais importantes no Modelo de Regressão por GradientBoosting

Feature	Importância	Descrição
v29	1	Geração Distribuída - Gás Natural(%)
v46	2	Consumo Médio Tensão A2 - 88 a 138 kV (GWh)
v37	3	Tarifa Média Tensão A1 - 230kV ou mais(R\$/MWh)
v47	4	Consumo Médio Tensão A3 - 69kV(GWh)
v49	5	Consumo Médio Tensão A4- 2,3 a 25 kV(GWh)


Gás Natural na Geração Distribuída



Tarifa Média Tensão A1



Consumo Médio



Propostas de Políticas Públicas


A) Para o Gás Natural na Geração Distribuída: Incentivo fiscal para uso do Biogás, de forma que a unidade consumidora que consiga fazer o manejo dos resíduos e utilizá-lo como Biogás de forma adequada e sustentável tenha redução dos principais impostos pagos para cada nível (IPTU, ISS, ICMS, etc). Além disso, para que exista a possibilidade de que cada grupo possa ter acesso aos meios para se criar o Biogás, medidas como treinamentos e linhas de crédito de baixo custo são importantíssimos. Desta forma, além de aumentar participação do Gás Natural na Geração Distribuída, melhorando o índice mais importante do modelo de regressão de machine learning, estaremos de fato melhorando a atual solução de manejo de resíduos e dando valor à uma fonte de energia subutilizada.

B) Para o Consumo nas Tensões A2, A3 e A4: Este é um item mais complicado, uma vez que demanda uma adequação da rede para aumento do fornecimento de uma dada tensão ou uma adequação da unidade consumidora à uma nova tensão de entrada. Assim, a proposta seria mais de estudos para uma melhor distribuição entre as faixas de tensões, de forma que as faixas de tensão tenham um consumo mais equilibrado entre si, deslocando unidades consumidoras de faixa quando isto for viável segundo estudo prévio e dando incentivos fiscais e linhas de crédito para adequação de equipamentos para a nova faixa de tensão.

C) Para a Tarifa Média na Tensão A1: A proposta para este caso é mais simples, de forma que a unidade consumidora que conseguir melhorar sua Eficiência Energética, na forma de redução de MWh em sua conta, tenha a tarifa reduzida proporcionalmente a redução de energia durante o ano, ou seja, se em 1 ano houver uma economia de 5%, a tarifa será reduzida em 5% e assim por diante, incentivando a Eficiência Energética e melhorando um índice importante no modelo de machine learning, o que levará a uma posição melhor no trilemma.

Pontos Críticos

Mapa de árvore dos Pontos Críticos da Experiência Científica



Os trabalhos futuros podem se concentrar nos pontos críticos deste problema, de forma que poderiam incluir:

- A) Análises com séries mensais e mais fontes de dados, que embora sejam mais difíceis de se conseguir, trariam um banco de dados mais complexo e que consolidaria melhor o modelo de machine learning;
- B) Comparativos com dados internacionais para uma análise de confiabilidade dos modelos de regressão;
- C) Aplicação de técnicas de Deep Learning, para uma análise mais robusta de variáveis.

Referências

- [1] Resultados do Procel: <http://www.procelinfo.com.br/main.asp?View={EC4300F8-43FE-4406-8281-08DDF478F35B}> (acesso em janeiro/2021);
- [2] Balanço Energético Nacional: <https://www.epe.gov.br/pt/publicacoes-dados-abertos/publicacoes/balanco-energetico-nacional-ben> (acesso em janeiro/2021);
- [3] Atlas da Eficiência Energética: <https://www.epe.gov.br/pt/publicacoes-dados-abertos/publicacoes/atlas-da-eficiencia-energetica-brasil-2019> (acesso em janeiro/2021);
- [4] Anuário Estatístico de Energia Elétrica: <https://www.epe.gov.br/pt/publicacoes-dados-abertos/publicacoes/anuario-estatistico-de-energia-eletrica> (acesso em janeiro/2021);
- [5] World Energy Trilemma Index: <https://www.worldenergy.org/publications?cat=69> (acesso em janeiro/2021);